

西南财经大学本科期末考试试题册（B）

（2025—2026学年第1学期）

以下各项由命题教师填写：

课程名称：机器学习（微课程）

命题教师：黄迟

适用对象（年级专业）：

使用试题的任课教师姓名：黄迟

试题说明：

- 1、考试类型：闭卷[☒] 开卷[☐]
- 2、本套试题共 六 道大题，共 3 页，完卷时间 100 分钟。
- 3、考试用品中除纸、笔、尺子外，可另带的用具有：
计算器[☒] 字典[☐] 等
(请在下划线上填上具体数字或内容，所选[]内打钩)

考试时间（由制卷方填写）：2025年10月30日

以下各项由学生填写：

任课教师：

年级专业：

学生姓名：

学 号：

- 考生注意事项：
1. 出示学生证（或身份证）和准考证于桌面左上角，以备查验。
 2. 拿到试卷后清点并检查试卷页数，如有重页、页数不足、空白页及印刷模糊等举手向监考教师示意调换试卷。
 3. 答题前先将试题册及答题纸上的任课教师、专业、年级、学号、姓名填写完整。
 4. 所有答案均需填写在答题纸上，答在试题册上无效。
 5. 考生不得携带任何通讯工具进入考场。
 6. 考试结束后，将试题册、答题纸和草稿纸等下发材料上交监考教师，不得带离考场。
 7. 严格遵守考场纪律。

一、单项选择题：(请将正确答案填在括号里，每小题 2 分，共 15 小题，30 分)

1. 以下哪项属于监督学习任务？（ ）
A. 对新闻文章自动分组 B. 根据用户行为预测是否会点击广告
C. 发现社交网络中的社区结构 D. 降低数据维度进行可视化
2. 使用ID3算法构建决策树时，若某个特征在所有样本中取值完全相同，则该特征的信息增益为：（ ）
A. 1 B. 0 C. 最大值 D. 无法定义
3. 逻辑回归模型输出为0.8，表示：（ ）
A. 属于正类的概率为80% B. 属于负类的概率为80%
C. 预测值为0.8个单位 D. 模型置信度为0.8
4. KNN算法中，若k值过大，可能导致：（ ）
A. 模型对噪声敏感 B. 决策边界过于复杂
C. 模型欠拟合 D. 训练时间显著增加
5. ID3决策树使用哪种指标选择划分属性？（ ）
A. 基尼指数 B. 信息增益 C. 信息增益比 D. 方差减少量
6. 支持向量机中，若数据线性可分，则：（ ）
A. 一定存在唯一最优解 B. 支持向量数量等于样本总数
C. 决策边界由所有样本决定 D. 无法处理高维数据
7. K-means算法迭代终止的常见条件是：（ ）
A. 达到最大迭代次数或质心变化小于阈值 B. 所有样本类别不再变化
C. 算法运算时间达到最大 D. 簇内平方和为零
8. 以下哪种情况说明模型泛化能力差？（ ）
A. 训练误差高，测试误差高 B. 训练误差低，测试误差高
C. 训练误差低，测试误差低 D. 训练误差高，测试误差低
9. 朴素贝叶斯分类器在处理连续特征时，常假设其服从：（ ）
A. 均匀分布 B. 泊松分布 C. 高斯分布 D. 伯努利分布
10. 合页损失函数主要用于：（ ）
A. 逻辑回归 B. 线性回归 C. 支持向量机 D. KNN

11. 在k折交叉验证中，若k=5，则每个样本被用于测试的次数是：（ ）
A. 1次 B. 5次 C. 4次 D. 不确定
12. KD树主要用于加速哪种算法？（ ）
A. 决策树 B. KNN C. K-means D. 朴素贝叶斯
13. 关于支持向量机的软间隔，以下说法正确的是：（ ）
A. 允许部分样本位于间隔带内甚至被错误分类
B. 要求所有样本严格位于间隔带外
C. 仅适用于线性可分数据 D. 会降低模型的泛化能力
14. 在梯度下降中，若损失函数为凸函数，则：（ ）
A. 一定收敛到全局最优 B. 可能陷入局部最优
C. 无法计算梯度 D. 必须使用随机梯度下降
15. 关于K-means聚类算法，以下说法正确的是：（ ）
A. 能自动确定最优聚类数量k B. 对非凸形状的簇结构识别效果很好
C. 目标是最小化所有样本到其所属簇质心的距离平方和
D. 不受初始质心选择的影响

二、判断题（正确打“√”，错误打“×”，每小题 1 分，共 10 题，10 分）

1. 线性回归可以用于分类任务。（ ）
2. 逻辑回归本质上是一种分类算法。（ ）
3. KNN算法在预测时需要计算测试样本与所有训练样本的距离。（ ）
4. 决策树的剪枝一定能提升测试准确率。（ ）
5. 支持向量机只能处理二分类问题。（ ）
6. K-means要求每个簇的形状是球形的。（ ）
7. 朴素贝叶斯在特征相关时性能一定很差。（ ）
8. 留出法比交叉验证更节省计算资源。（ ）
9. 梯度下降法中，批量梯度下降每次更新使用全部训练样本。（ ）
10. 聚类属于监督学习任务。（ ）

三、名词解释（每题3分，共5题，15分）

1. 欠拟合 2. 验证集 3. 精确率（Accuracy） 4. 留一法 5. 泛化误差

四、简答题（每题4分，共5题，20分）

1. 监督学习与非监督学习有什么不同？
2. 为什么信息增益会偏向取值较多的特征？
3. 决策树剪枝的目的是什么？分为哪两类？
4. 简述支持向量机中“最大间隔”的含义。
5. KNN算法中 k 值选择对预测结果有何影响？

五、计算题（共1题，10分）

1. 有 5 个训练样本（二维）：A(1,1) 正类，B(2,2) 正类，C(4,5) 负类，D(5,5) 负类，E(1,2) 正类。测试点为 (2,3)，分别使用曼哈顿距离和欧氏距离，用 k 近邻(kNN, $k=3$) 算法判断其类别。

六、场景应用题（15分）

场景描述：某高校希望预测学生是否可能在下学期退学，以便提前干预。已知可获取的数据包括：学生上学期GPA、出勤率、是否参与社团活动（是/否）、家庭经济状况（低/中/高）、是否有助学贷款（是/否）、历史退学记录（标签：退学/未退学）。

问题：你觉得还应采集哪些数据用于问题分析？（5分）你会选择哪种机器学习方法？为什么？（5分）如何评估模型的有效性？（需说明至少两个评估指标及其适用原因，5分）