

西南财经大学本科期末考试试题册（B）

（2024—2025学年第1学期）

以下各项由命题教师填写：

课程名称：自然语言处理 命题教师：赵宇 陈星延 陈中普 潘宁宁

适用对象（年级专业）：2022级计算机科学与技术；2022级人工智能
使用试题的任课教师姓名：赵宇 陈星延 陈中普 潘宁宁

试题说明：

- 1、考试类型：闭卷☒ 开卷☐
- 2、本套试题共 四 道大题，共 4 页，完卷时间 120 分钟。
- 3、考试用品中除纸、笔、尺子外，可另带的用具有：
计算器☒ 字典☐ 等
(请在下划线上填上具体数字或内容，所选☐内打钩)

考试时间（由制卷方填写）：

以下各项由学生填写：

任课教师： 年级专业：
学生姓名： 学 号：

- 考生注意事项：
- 1.出示学生证（或身份证）和准考证于桌面左上角，以备查验。
 - 2.拿到试卷后清点并检查试卷页数，如有重页、页数不足、空白页及印刷模糊等举手向监考教师示意调换试卷。
 - 3.答题前先将试题册及答题纸上的任课教师、专业、年级、学号、姓名填写完整。
 - 4.所有答案均需填写在答题纸上，答在试题册上无效。
 - 5.考生不得携带任何通讯工具进入考场。
 - 6.考试结束后，将试题册、答题纸和草稿纸等下发材料上交监考教师，不得带离考场。
 - 7.严格遵守考场纪律。

一、单项选择题（20分，每小题2分）

- 1) 假设你正在开发一个机器学习模型，旨在对大量文本数据进行分类。该模型需要识别和捕捉文本中的语义关系，以更好地区分不同类别的文本（例如，新闻文章的分类标签可能包括“体育”、“政治”、“科技”等）。在以下列出的技术中，哪一项技术最适合用于学习词汇的语义特征，从而支持模型进行准确的文本分类？
 - A. TF-IDF
 - B. 主成分分析
 - C. Word2Vec
 - D. 依存关系分析
- 2) 在当前大模型训练过程中，下面哪种技术没有被使用？
 - A. 提示学习
 - B. 指令微调
 - C. 预训练
 - D. 人工反馈的强化学习
- 3) 在Word2Vec算法的哪种模型中，目标词作为输入，而上下文的词则作为输出？
 - A. Skip-gram
 - B. RNN
 - C. CBOW
 - D. GPT
- 4) GLM模型的特点，选择下列哪个选项最准确地描述了它的核心架构组成：
 - A. 仅包含编码器（Encoder Only）
 - B. 仅包含解码器（Decoder Only）
 - C. 编码器-解码器结构，但与传统的Transformer架构有显著差异
 - D. 循环神经网络（Recurrent Neural Network, RNN）
- 5) 在使用束搜索（Beam Search）算法进行自回归答案生成时，下列关于束宽度（Beam Width）的描述正确的是？
 - A. 束宽度越小，搜索范围更广，有更高可能生成多样性高的序列
 - B. 束宽度决定了在每个时间步保留的候选序列数量，较大的束宽度通常会增加生成序列的质量，但也会增加计算量
 - C. 当束宽度为 1 时，束搜索等同于暴力搜索，保证生成全局最优解
 - D. 束宽度的设置与生成质量无关，只会影响搜索的复杂度
- 6) 关于大语言模型中的绝对位置编码和相对位置编码的概念与作用，以下哪项描述正确？
 - A. 绝对位置编码为每个位置分配固定的编码向量，适合捕捉序列中的长距离依赖关系
 - B. 绝对位置编码始终为每个位置分配固定的向量，即使输入不同句子，第10个位置的编码向量始终相同
 - C. 相对位置编码与绝对位置编码相同，均为每个序列位置分配固定编码
 - D. 相对位置编码不适合捕捉序列中位置间的动态关系

- 7) 在强化学习训练框架中, 哪种模型使用了人工反馈来优化模型的生成结果, 以增强模型的响应质量?
- A. GPT-3
 - B. BERT
 - C. GPT-2
 - D. InstructGPT
- 8) 在大模型的交叉注意力机制中, 假设我们有两种不同的模态输入(文本和图像特征), 图像特征通过交叉注意力机制融入到模型中, 在交叉注意力计算中, Q是查询, K是键, V是值, 请问下面描述种通常哪个是正确的?
- A. Q 和 K 分别代表文本和图像的特征表示, 交叉注意力A计算的是这两者的相似性
 - B. Q、V 和 K 分别代表文本、图像和图像的特征表示, 计算的是同一模态内的相似性
 - C. Q、V 和 K 分别代表图像、文本和文本的特征表示, 计算的是不同模态内的相似性
 - D. Q 和 K 分别代表图像和文本的标签, 交叉注意力A计算的是标签间的相似性
- 9) 在 Transformer 模型的序列生成任务中, 引入带掩码的注意力机制 (Masked Attention Mechanism) 的主要作用是什么? 以下选项中, 哪项更准确地描述了该机制的影响及其在生成任务中的关键作用?
- A. 带掩码的注意力机制使模型能够在不同的序列位置使用不同的注意力权重, 以增强模型的上下文敏感性。
 - B. 带掩码的注意力机制确保模型在生成序列的过程中只能访问当前位置及其之前的信息, 从而防止未来信息泄漏。
 - C. 带掩码的注意力机制允许模型关注到序列中的多个位置, 但仅限于与当前位置在同一层次的上下文范围。
 - D. 带掩码的注意力机制显著提高了模型在长序列中的信息处理能力, 使其能够更好地捕捉远距离的依赖关系。
- 10) 下面哪一项不属于传统自动评估方法。
- A. 基于N-gram的模型评估方法
 - B. 基于词向量的模型评估方法
 - C. 基于编辑距离的模型评估方法
 - D. BERTScore的模型评估方法

二、填空题(10分, 每空题1分, 任选10个空填写即可)

1. _____利用幂律关系来描述大语言模型的性能随模型规模(参数数量、训练数据量和计算资源)的变化规律。
2. Transformer 的输入表示分为词元嵌入和_____。
3. 在使用大模型生成任务中, 通过设置参数_____可以调整模型回复的随机性。
4. 在 Transformer 架构的 Encoder 模块中, 如果 K 是 $n \times d_k$, V 是 $n \times d_v$, 若计算注意力得分时采用缩放点积操作, 那么缩放是除以_____。
5. Decoder 模块在解码时, 为了使得输出序列能够适时停止, 可以使用_____等策略(回答一种即可)。
6. 对于 Transformer 架构, 计算交叉注意力的_____来自于 Encoder 模块。

7. ALBERT 模型对 BERT 的改变之一是使用了嵌入参数因子分解，如果词表是 V ，新引入词嵌入长度是 E ，隐藏层是 H 。如果原始 BERT 的词元嵌入参数量是 $V \times H$ ，那么 ALBERT 的词元嵌入参数量是_____。
8. 2024 年 4 月，Meta 发布了 Llama 3.1 8B 模型，这里的 B 表示_____。
9. 提示工程中，用户可以通过提供一些示例来告诉模型任务的含义及意图，这被称为_____。
10. NLP 中_____任务其核心目标是从非结构化文本中准确识别和分类具有特定语义价值的实体，并将它们归类到预先定义的类别中。
11. 为了使 LLM 生成有用、诚实和无害的回复，一般需要在预训练后_____。
12. 在模型推理阶段，考虑 T 个时间步，字表大小是 V ，束搜索每次选择当前 top-K 个概率最大的词元，其总体时间复杂度是_____。

三、简答题（30分，每小题5分）

- 1 简单介绍CBOW模型训练word2vec的核心过程。
- 2 请简要描述seq2seq模型的主要组成部分，以及各组成部分的功能。
- 3 请描述BERT模型与GPT-1模型的预训练任务的差异。
- 4 ViT 模型是一种利用transformer架构来处理图像分类问题的深度学习模型。假设输入图像维度为 $H \times W \times C$ ，其中 (H, W) 为图像分辨率， C 为通道数。请详细描述如何切分该图像，以获得合适的图像嵌入并作为transformer模型的输入。
- 5 请设计一个预训练模型指令微调任务，并举例说明该任务的输入、输出和指令。
- 6 请描述以下三个大模型框架的不同之处：GLM, ROBERTA, LLAMA。

四、计算题（40分）

1. 假设你正在使用 LoRA 对一个大型语言模型的线性层进行微调。原始模型中的某个线性层的权重矩阵 W 大小为 $d \times k$ ，其中 $d=128$ 表示输入维度， $k=756$ 表示输出维度。如果矩阵的秩 $r=6$ 。
 - 1) 计算使用 LoRA 微调时需要更新的参数量。相较全量微调，使用 LoRA 微调需要更新的参数量能降低多少？
 - 2) QLoRA 是一种结合了 量化 和 LoRA（Low-Rank Adaptation）的技术，请简述 QLoRA 相较 LoRA 的优点。

2 下表展示了不同Transformer-based的模型

	Configurations						
	N	d_model	d_ff	h	d_k	d_v	vocabulary tokens
Transformer Base	6	512	2048	8	64	64	37000
Transformer Big	6	1024	4096	16	64	64	37000
GPT1*	12	768	3072	12	64	64	40000
Bert base*	12	768	3072	12	64	64	30000
Bert large*	24	1024	4096	16	64	64	30000
GPT2*	48	1600	3072	25	64	64	50257
GPT1	12	768	3072	12	64	64	40000
Bert base	12	768	3072	12	64	64	30000
Bert large	24	1024	4096	16	64	64	30000
GPT2	48	1600	3072	25	64	64	50257

每列参数的含义如下：

- **N**: 模型的层数，代表Transformer块的数量，层数越多，模型越深。
- **d_model**: 模型的隐藏层维度，每个词向量的表示维度，决定了词嵌入的大小。
- **d_ff**: 前馈层的维度，通常大于**d_model**，用于在信息传递过程中进行非线性转换。
- **h**: 多头注意力机制的头数。多个注意力头使得模型可以在输入序列的不同位置关注不同信

息，提升捕捉特征的能力。

- **d_k** 和 **d_v**: 注意力机制中每个头的“键值”（key）和“值”（value）向量的维度，决定了每个注意力头能够关注的内容范围。
- **vocabulary tokens**: 词汇表大小，代表模型能够识别的词或子词的总数量。

题目：

- (1) 请简单画出GPT模型的基本架构图。
- (2) 计算 GPT-1 模型的总参数量。给出每个部分的计算过程。（15分）

3. 下面是来自一个语料库其中 8 个单词的二元语法概率。比如说，给定单词 i，后面是 want 的概率是 0.32；给定单词 to，后面是 i 的概率是 0.0009。

	i	want	to	eat	italian	food	lunch	spend
i	0.0021	0.32	0	0.1	0	0	0	0.0008
want	0.0023	0	0.65	0.0012	0.0067	0.0063	0.0055	0.0012
to	0.0009	0	0	0.27	0.0009	0	0.0026	0.088
eat	0	0	0.0028	0	0.022	0	0.055	0
italian	0.0065	0	0	0	0	0.51	0	0.0064
food	0.014	0	0.013	0	0.0009	0	0.0038	0
lunch	0.006	0	0	0	0	0	0	0
spend	0.0037	0	0.0035	0	0	0	0	0

假设使用<BEGIN>表示句子开头，<END>表示句子结尾。如果已知 $P(i|<BEGIN>) = 0.22$ ， $P(<END>|food) = 0.63$ 。

- 1) 请基于二元语法模型计算句子<BEGIN>i eat italian food<END>的概率（保留小数点后 7 位）。
- 2) 假设整个词表大小是2000（包括<BEGIN>和<END>），每个词使用其ID表示（int32），概率使用float64表示。如果所有三元语法的统计信息通过四元组(i, j, k, p)保存。请估计其内存占用（单位GB，保留整数）。