

西南财经大学本科期末考试试题册（A）

（2025—2026学年第1学期）

以下各项由命题教师填写：

课程名称：自然语言处理 命题教师：赵宇 陈中普 陈珍珠 黄士罗

适用对象（年级专业）：2023级计算机科学与技术；2023级人工智能；2023级
人工智能（智能金融光华实验班）

使用试题的任课教师姓名：赵宇 陈中普 陈珍珠 黄士罗

试题说明：

- 1、考试类型：闭卷☒ 开卷☐
- 2、本套试题共 四 道大题，共 7 页，完卷时间 120 分钟。
- 3、考试用品中除纸、笔、尺子外，可另带的用具有：
计算器☒ 字典☐ 等
(请在下划线上填上具体数字或内容，所选☐内打钩)

考试时间（由制卷方填写）：

以下各项由学生填写：

任课教师：

年级专业：

学生姓名：

学 号：

- 考生注意事项：
1. 出示学生证（或身份证）和准考证并放置于桌面左上角，以备查验。
 2. 领取试卷后清点并检查试卷页数，如有重页、页数不足、空白页及印刷模糊等举手向监考教师示意调换试卷。
 3. 答题前先将试题册及答题纸上的任课教师、专业、年级、学号、姓名等信息填写完整。
 4. 所有答案均需填写在答题纸上，填写在试题册上无效。
 5. 考生不得携带任何通讯工具进入考场。
 6. 考试结束后，将试题册、答题纸和草稿纸等材料上交监考教师，不得带离考场。
 7. 严格遵守考场纪律。

一、选择题（每小题 2 分，共 30 分）

1. 关于词向量的分布式，以下选项正确的是（ ）。
 - A. 一般依赖分布式计算技术训练得到。
 - B. 得到的向量是低维稠密的。
 - C. 得到的向量一般就是独热编码。
 - D. 高频词汇对应的词向量维度更小，而低频词汇对应的词向量维度更大。
2. 关于 Word2Vec 技术，以下选项正确的是（ ）。
 - A. 它是静态编码，意味着无法编码未登录词。
 - B. CBOW 模型是根据中心词预测上下文。
 - C. Skip gram 模型需要对上下文向量进行求平均。
 - D. 它保留了词序信息，因此能够编码词语之间的语义相似性。
3. 关于 N 元文法（n-gram）模型，以下说法正确的是（ ）。
 - A. 它常常需要平滑或回退机制，用于克服语料库稀疏导致的问题。
 - B. 它基于 N 阶马尔科夫链假设，即一个词出现的概率依赖前面 N-1 个词。
 - C. N 元文法模型往往需要通过 RNN 或 LSTM 训练得到。
 - D. N 元文法模型是基于条件概率的加权平均。
4. 下面是哪种典型的自然语言处理任务？

正向

负向

这家店环境不错，但服务很糟糕

- A. 自动分词
 - B. 命名实体识别
 - C. 词性标注
 - D. 情感分析
5. 关于 Seq2Seq 模型，以下选项错误的是（ ）。
 - A. Seq2Seq能够处理输入输出长度不同的情况，这是和传统RNN的最大区别。
 - B. Seq2Seq模型也叫编码器-解码器模型。
 - C. 在训练过程中，Seq2Seq常常使用Teacher Forcing的技术。
 - D. 在Seq2Seq中无法使用注意力机制。
 6. 关于注意力机制，以下选项正确的是（ ）。
 - A. 在自注意力中，Query、Key和Value总是来自不同的输入序列。

- B. 多头注意力机制的主要作用是并行地捕捉不同子空间的特征表示。
- C. 假设输入是d维,经过Transformer中一个layer(也叫block)后,维度一般是d*h,其中h是多头的数量。
- D. 在自注意力中,Query和Value的维度要求一致。
7. 关于交叉注意力机制,以下选项正确的是 ()。
- A. 与自注意力机制不同,它不使用softmax,而是直接计算Q和K的点积获得注意力得分。
- B. 它的Value和Key来自编码器,而Query来自解码器。
- C. 假设Query维度为 $N \times D$,那么Key维度也一定是 $N \times D$ 。
- D. 在仅解码器(Decoder-only)模型中也存在该模块。
8. 给定输入向量 $x=[1,1,3,3]$,层归一化公式为 $LN(x_i) = (x_i - \mu) / \sqrt{\sigma^2 + \epsilon}$,忽略 ϵ ,请问对第一个元素1进行LN后的结果是多少? ()
- A. -0.25
- B. -0.5
- C. -1
- D. -4
9. 关于Transformer的解码器,以下选项正确的是 ()。
- A. 解码器的自注意力层(Self-Attention)不进行掩码(mask),以便能够同时参考未来和过去的目标词。
- B. 输出层的权重矩阵一般和输入层共享。
- C. BERT是典型的仅依赖解码器的语言模型。
- D. 在推理阶段,解码器一次性输入整个目标序列,通过并行计算同时生成所有输出词。
10. 关于GPT模型,以下选项正确的是 ()。
- A. 它是典型的自回归模型。
- B. GPT-3引入的少样本(few-shot)的核心是通过高效微调技术实现模型性能的提升。
- C. GPT-3.5支持多模态输入。
- D. GPT的多头注意力中,每个头共享相同的线性投影矩阵,以减少参数量。
11. 关于对齐微调,以下选项错误的是 ()。

(1). 对齐微调的核心目标是让模型不仅生成语法正确的文本，还要符合人类偏好和安全规范 (2). 对齐微调通常直接在原始大规模语言模型上用完整的监督信号进行训练，无需奖励模型或强化学习 (3). 对齐微调可以结合RLHF或偏好数据，提升模型在复杂指令上的表现 (4). 对齐微调只适用于小模型，对大模型不起作用 (5). 对齐微调的训练过程可能会引入“过拟合偏好”的风险，因此需要在多样化数据上进行验证

- A. (2) (3) (4) (5) B. (2) (4) C. (3) (5) D. (4) (5)

12. 关于 CLIP 模型，以下选项正确的是（ ）。

- A. CLIP模型中，用于最终计算相似度矩阵的图形特征与文本特征维度可以不同。
B. CLIP 使用自回归语言模型（如 GPT）对文本进行编码，然后将文本特征直接加到图像特征上进行分类。
C. CLIP模型的核心是对比学习，适用于零样本分类。
D. CLIP 只能用于图像分类任务，无法应用于文本-图像检索或生成任务。

13. 关于大模型微调技术，以下选项正确的是（ ）。

- A. 在 LoRA 微调中，模型原始权重矩阵被完全替换为低秩矩阵，以减少模型容量。
B. 提示工程技术本质上也是一种微调技术，能够提升模型在下游任务的能力。
C. 实验表明，模型微调的数据量也符合缩放定律（Scaling Law），即更多微调数据一定能带来更加显著的模型能力提升。
D. 微调的过程是基于有标注数据的有监督学习，这和预训练不同。

14. 关于大模型评估，以下选项正确的是（ ）。

- A. 随着模型能力的提升，目前LLM-as-Judge（大模型作为裁判）的做法变得普及。
B. BLUE是一种典型的LLM-as-Judge方法下的评估指标，最早用于机器翻译任务。
C. 困惑度是评估大模型表现的常用指标之一，一般困惑度越低越好。
D. BERTScore综合了BERT模型的泛化能力和n-gram的可解释性。

15. 关于大模型，以下选项正确的是（ ）。


- A. 早期的大模型不具备联网能力，而现在从HuggingFace下载的最先进模型（如GPT-5、DeepSeek V3.2）均支持自动联网功能。
B. 幻觉是大模型的固有问题。
C. 给定一个固定输入，大模型的输出一定具有随机性。
D. 思维链技术表明大模型具备推理能力，它只能应用到推理模型（如DeepSeek R1）上。

二、填空题（每空 2 分，共 20 分）


1. 2025 年 11 月，月之暗面发布 Kimi K2 Thinking 模型，它有 32B 的激活参数，这里的 B 表示_____。
2. CBOW 模型会将训练窗口中_____的独热表示映射为对应的词向量。
3. BERT 模型的输入除了嵌入编码、_____，还有段编码。
4. BERT 模型的预训练任务包括 Masked Language Modeling (MLM) 和 _____，其中后者用于捕捉句子间关系。
5. BLIP 模型在训练中结合了对比学习、_____和语言建模，使模型既能进行检索，也能进行生成任务。
6. ALBERT 模型的主要创新是_____和跨层参数共享。
7. 假设 Transformer 模型中，输入序列长度是 N，模型的维度是 d，那么计算自注意力的时间复杂度是_____。
8. 在 Transformer 解码器的交叉注意力层中，Value 是由_____经对应的映射矩阵映射得到。
9. 为了降低大模型在推理阶段的显存占用，可以使用_____等技术。
10. 考虑权重矩阵 $W \in \mathcal{R}^{d \times k}$ ，如果使用秩为 r 的 LoRA 微调，则引入的新增矩阵总规模是_____。

三、简答题（每小题 5 分，共 15 分）

1. 根据下面 Skip gram 的模型示意图，请回答 1) 模型中一共有多少个权重矩阵？2) 在引入层次 softmax 情况下，如果上下文长度是 C，嵌入维度是 N，词表大小为 V，一个训练窗口的时间复杂度多少？



2. 在 transformer 模型中，编码器的多头自注意力通常不使用掩码机制，请解释原因？
3. 下面是 CLIP 模型的一个运用，请简述其工作原理。



四、分析及计算题（10+10+15 分，共 35 分）

1. 考虑下面的语料库，请计算句子 “I enjoy Python” 的二元文法模型概率，并采用加一平滑处理零概率问题。（提示：加一平滑可以被表示为 $P(w_i|w_{i-1}) = (c(w_{i-1}, w_i) + 1)/(c(w_{i-1}) + V)$, 其中 c 表示词频统计，而 V 是词表大小，忽略大小写;结果保留 5 位小数）。

<s> I love NLP </s>
 <s> NLP is fun </s>
 <s> I enjoy learning models </s>
 <s> Learning models is interesting </s>
 <s> I enjoy coding in Python </s>
 <s> Python makes coding easy </s>
 <s> Deep learning improves NLP </s>

2. 假设 Transformer 模型有一个长度为 2 的输入序列，它的词向量维度为 3:

$$X = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$$

模型使用 2 个注意力头，其注意力头的权重矩阵分别如下：

$$W_1^Q = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}, W_1^K = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}, W_1^V = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}$$

$$W_2^Q = \begin{bmatrix} 0 & 1 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}, W_2^K = \begin{bmatrix} 0 & 1 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}, W_2^V = \begin{bmatrix} 0 & 1 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}$$

1) 请使用点积注意力，计算第一个头和第二个头的输出（Softmax 的计算公式为：

$$\text{softmax}(z_i) = \exp(z_i) / \sum_j \exp(z_j)$$

2) 假设 $W^o = \begin{bmatrix} 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 \end{bmatrix}^T$ ，计算多头自注意力的输出向量。

3. 下面是 Qwen3 某个模型在 HuggingFace 上的配置文件，其中关键信息已加粗并添加解释：

```
{  
  
"architectures": [ "Qwen3ForCausalLM" ]  
  
"attention_bias": false, #注意力无偏置  
  
"attention_dropout": 0.0,  
  
"bos_token_id": 151643,  
  
"eos_token_id": 151645,  
  
"head_dim": 128, #dk 和 dv  
  
"hidden_act": "silu", #MLP 激活函数  
  
"hidden_size": 1024, #模型的维度  
  
"initializer_range": 0.02,  
  
"intermediate_size": 3072, #MLP 层的大小  
  
"max_position_embeddings": 40960,  
  
"max_window_layers": 28,  
  
"model_type": "qwen3",  
  
"num_attention_heads": 16, #Q 多头的数量  
  
"num_hidden_layers": 28, #Transformer 层的数量  
  
"num_key_value_heads": 8, #KV 多头的数量  
  
"rms_norm_eps": 1e-06,  
  
"rope_scaling": null,
```

```

"rope_theta": 1000000,

"sliding_window": null,

"tie_word_embeddings": true, # 输入和输出的嵌入层共享

"torch_dtype": "bfloat16",

"transformers_version": "4.51.0",

"use_cache": true,

"use_sliding_window": false,

"vocab_size": 151936 # 词表大小
}

```

与传统 Transformer 不同，

- 每两个 Q 共享一个 KV。
- 每个 Query 和 Key 均进行轻量级的 RMSNorm 归一化操作（公式如下），Query 的多头共享 RMSNorm 权重 Key 的多头也共享 RMSNorm 权重；Add & Norm 中也是使用 RMSNorm。

$$y_i = \frac{x_i}{\text{RMS}(x)} * \gamma_i, \quad \text{where} \quad \text{RMS}(x) = \sqrt{\epsilon + \frac{1}{n} \sum_{i=1}^n x_i^2}$$

（其中 γ 为权重）

- MLP 层采用的是 SiLU 门控网络（公式如下），其中 SiLU 是激活函数，不改变维度，而 $\odot$ 表示 Hadamard 积（按位相乘）。

$$\text{MLP}(x) = W_{\text{down}} (\text{SiLU}(W_{\text{gate}}x) \odot (W_{\text{up}}x))$$

- （和 GPT-2 类似）在所有 Transformer Block 之后，也有一个 RMSNorm。
- 整体结构和 GPT-2 类似，注意力层和前馈层前均有 RMSNorm 归一化。
- 均没有偏置。

请据此画出模型整体架构示意图（参考经典的 Transformer 结构图，无需画出注意力和 MLP 模块细节），并估算该模型的参数量, 要求给出具体计算过程。