

西南财经大学本科期末考试试题册（B）

（2025—2026学年第1学期）

以下各项由命题教师填写：

课程名称：自然语言处理 命题教师：赵宇 陈中普 陈珍珠 黄士罗

适用对象（年级专业）：2023级计算机科学与技术；2023级人工智能；2023级
人工智能（智能金融光华实验班）

使用试题的任课教师姓名：赵宇 陈中普 陈珍珠 黄士罗

试题说明：

- 1、考试类型：闭卷[☒] 开卷[]
- 2、本套试题共 四 道大题，共 6 页，完卷时间 120 分钟。
- 3、考试用品中除纸、笔、尺子外，可另带的用具有：
计算器[☒] 字典[] 等
(请在下划线上填上具体数字或内容，所选[]内打钩)

考试时间（由制卷方填写）：

以下各项由学生填写：

任课教师：

年级专业：

学生姓名：

学 号：

- 考生注意事项：
1. 出示学生证（或身份证）和准考证并放置于桌面左上角，以备查验。
 2. 领取试卷后清点并检查试卷页数，如有重页、页数不足、空白页及印刷模糊等举手向监考教师示意调换试卷。
 3. 答题前先将试题册及答题纸上的任课教师、专业、年级、学号、姓名等信息填写完整。
 4. 所有答案均需填写在答题纸上，填写在试题册上无效。
 5. 考生不得携带任何通讯工具进入考场。
 6. 考试结束后，将试题册、答题纸和草稿纸等材料上交监考教师，不得带离考场。
 7. 严格遵守考场纪律。

一、单项选择题（每小题2分，共30分）

1. 在下列关于文本表示方法的描述，正确的是（ ）
 - A. Bag-of-Words（BOW）表示忽略了词序信息
 - B. One-hot编码能精确表示词语之间的语义相似性
 - C. One-hot编码的向量维度通常与词表大小无关
 - D. 词向量表示完全依赖于人工设计特征
2. 下列哪项是基于2阶马尔科夫链的统计语言模型表达式（ ）
 - A. $P(w_1, w_2, \dots, w_L) = \prod_{i=1}^L P(w_i)$
 - B. $P(w_1, w_2, \dots, w_L) = \prod_{i=1}^L P(w_i | w_{i-1})$
 - C. $P(w_1, w_2, \dots, w_L) = \prod_{i=1}^L P(w_i | w_{i-1}, w_{i-2})$
 - D. $P(w_1, w_2, \dots, w_L) = \prod_{i=1}^L P(w_i | w_{i-1}, w_{i-2}, w_{i-3})$
3. 关于循环神经网络（RNN），下列说法中哪一项是正确的？（ ）
 - A. RNN的每个时间步之间没有参数共享
 - B. RNN通过引入隐藏状态来捕捉序列中的依赖关系
 - C. RNN只能处理固定长度的输入序列
 - D. RNN在反向传播中不会出现梯度消失或梯度爆炸问题
4. 在Seq2Seq模型中，解码器的隐藏状态计算表达式为： $h'_t = f(c, h'_{t-1}, y_{t-1})$ ，请问 c 是指什么？（ ）
 - A. 解码器的输入词向量
 - B. 上一时间步解码器的隐藏状态
 - C. 编码器输出的上下文向量
 - D. 当前时间步解码器的输出预测
5. 传统的Seq2Seq模型中，长序列输入容易导致信息丢失。引入注意力机制后，模型能够在生成每个输出时关注输入序列的不同部分。下列关于注意力机制的描述，正确的是（ ）
 - A. 注意力机制只对解码器的隐藏状态进行归一化处理，与编码器无关。
 - B. 注意力机制为解码器提供了对整个输入序列的加权表示，缓解了长序列信息遗忘的问题。
 - C. 注意力机制要求输入和输出序列长度必须相等。
 - D. 注意力机制只在训练阶段使用，推理阶段不使用

6. 在Seq2Seq模型中，Teacher Forcing与Free-running的主要区别是（ ）
- A. Teacher Forcing使用模型自己生成的输出作为下一步输入，而Free-running使用真实标签作为下一步输入
 - B. Teacher Forcing和Free-running都始终使用模型预测作为下一步输入
 - C. Teacher Forcing使用真实标签作为下一步输入，而Free-running使用模型自己生成的输出作为下一步输入
 - D. 两者的优化器不同：Teacher Forcing使用Adam，Free-running使用SGD

7. 在序列生成中，使用束搜索时，假设当前时间步的模型输出概率如下：

单词	A	B	C
概率	0.5	0.3	0.2

当前束宽为2，上一时间步的束序列概率为：序列S1的概率为0.6，序列S2的概率为0.4，请问下一时间步更新后的束序列应该是下列哪个组合？（ ）

- A. S1+A, S2+A
 - B. S1+A, S1+B
 - C. S1+A, S2+B
 - D. S1+B, S2+A
8. 在标准Transformer模型中，引入位置嵌入的主要原因是（ ）
- A. 为了增加模型容量，使每个词向量维度加倍，从而提升表示能力。
 - B. 为了替代注意力机制，使模型只依靠位置编码生成序列。
 - C. 为了减少训练时序列长度对性能的影响，使模型可以忽略词的顺序。
 - D. 为了向模型提供序列中各词的位置信息，使自注意力能够区分不同位置的词。
9. 在基于Transformer的语言模型中，解码器最后一层的输出向量 z_t 会经过softmax层。softmax的主要作用是（ ）
- A. 对输出向量进行加权，使概率最大的词自动得到增强。
 - B. 将输出向量标准化，使平均值为0，方差为1，从而稳定训练。
 - C. 将向量 z_t 转换为每个词在词表中的概率分布，并且概率和为1。
 - D. 将向量 z_t 映射到固定长度的向量空间，方便后续线性层处理。
10. 在Transformer 模型中，每个子层（如多头注意力或前馈网络）后一般会使用“add & Norm”，下列哪一项是正确的操作顺序？（ ）
- A. 先将子层输出加上输入残差，再进行归一化

- B. 先对子层输出进行归一化，再加上输入残差
- C. 先将输入残差加权，再与子层输出求和
- D. 先将子层输出做Dropout，再与输入残差相加。
11. Bert模型用到了下列哪两种模型技术（训练策略）进行训练？（ ）
- A. 自回归语言模型（AR）和句子顺序预测（SOP）
- B. 掩码语言模型（MLM）和下一句预测（NSP）
- C. 自回归语言模型（AR）和下一句预测（NSP）
- D. 掩码语言模型（MLM）和句子顺序预测（SOP）
12. 关于 ViT（Vision Transformer）模型，以下选项正确的是（ ）。
- A. 它采用了典型的Transformer架构，分为视觉编码器和视觉解码器。
- B. 由于图片是二维的，ViT不再使用位置编码。
- C. 假设图片分辨率是 96×96 ，切分的块是 16×16 ，那么进入编码器的序列长度为37。
- D. 假设图片的通道数为3，切分的块是 16×16 ，那么ViT中嵌入维度一定是768。
13. 关于大模型预训练，以下列说法正确的是（ ）
- A. 大模型的预训练主要涉及数据源和分布式训练两个关键方面
- B. 书籍数据集作为长形式文本的优质来源，是目前LLMs中使用最广泛的数据源
- C. 在训练数据量有限的情况下，增加模型参数量和更长训练周期可以改善性能
- D. 预训练数据中出现较高比例的重复样本能够在训练初期提供更稳定的梯度信号，从而改善模型的早期收敛效率。
14. 以下说法正确的是（ ）
- A. 指令微调主要作用是提升模型在特定任务上的专业化能力，因此常使用单一任务的数据来避免跨任务干扰。
- B. 只要扩展模型的参数规模，即便训练数据不足，也会触发涌现能力的出现
- C. 模型规模是影响模型性能的重要因素，模型损失和非嵌入参数量呈现线性关系
- D. 准确率、BLEU和ROUGE等指标常用来评估大模型生成文本的质量
15. 下列哪种提示属于零样本CoT提示？（ ）
- A. “请解释 $15 \div 3$ 的计算过程，然后给出答案。”
- B. “已知以下示例： $2+3=5$ ， $4+5=9$ ，请计算 $6+7$ 并解释过程。”
- C. “答案是5。”
- D. “请直接输出 $6+7$ 的结果。”

二、填空题（每空2分，共20分）

1. 在自然语言处理中，_____是基本的语言单位。
2. Word2Vec 的 Skip-gram 模型通过给定_____预测_____，而 CBOW 模型恰好相反。
3. 在 bigram 模型中，已知词表大小为 10， w_{i-1}, w_i 的计数为 $C(w_{i-1}, w_i)=0$ ，前一个词计数为 $C(w_{i-1})=10$ 。采用加 1 平滑，计算 $P(w_i|w_{i-1})= \underline{\hspace{2cm}}$ 。
4. 神经概率语言模型为确保模型输出的是一个有效的概率分布，需满足两个约束条件：_____和非零概率约束。
5. 假设 RNN 隐藏状态维度为 d_h ，输入维度为 d_x ，则隐藏状态更新公式中隐藏状态到隐藏状态的权重矩阵 W_h 的维度为_____，输入到隐藏状态的权重矩阵 W_x 的维度为_____。
6. 在引入注意力机制的 Seq2Seq 模型中，计算注意力权重的常用方法是对编码器隐藏状态和解码器隐藏状态做点积，再通过 softmax 归一化。假设编码器的第 i 个隐藏状态记为 h_i ，解码器时间步 t 的隐藏状态记为 s_t ，那么注意力权重 α_{ti} 的计算公式为_____。
7. 在大模型评估中，_____适合大规模快速量化模型性能，但难以准确反映文本的语义合理性和逻辑性；_____可以评价模型生成文本的流畅性、逻辑性和任务完成度，但通常耗时较长、成本较高。

三、简答题（每小题5分，共15分）

1. ALBERT模型是如何减少参数数量的？请结合模型的嵌入层和编码器层给出说明。
2. 假设 k 表示在输入序列的位置，其旋转矩阵是：

$$R_k = \begin{bmatrix} \cos k\theta & -\sin k\theta \\ \sin k\theta & \cos k\theta \end{bmatrix}$$

x_i 对应的查询向量是 Q_i ， x_j 对应的键向量是 K_j ，应用旋转位置编码（RoPE）后的查询向量和键向量分别为 $Q'_i = R_i q_i$ 和 $K'_j = R_j K_j$ 。从注意力分数计算的角度进行推导说明为什么 RoPE 能够捕捉不同位置（例如 i 与 j ）之间的动态关系（需要写详细的推导步骤）。

3. 请解释LoRA在大模型微调中的核心原理，以及它是如何实现训练加速和参数高效更新的。

四、计算题（10+10+15，共 35 分）

1. 假设 Transformer 模型有一个长度为 2 的输入序列，它的词向量维度为 3：

$$X = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

模型使用 2 个注意力头，其注意力头的权重矩阵分别如下：

$$W_1^Q = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}, W_1^K = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}, W_1^V = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}$$

$$W_2^Q = \begin{bmatrix} 0 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}, W_2^K = \begin{bmatrix} 0 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}, W_2^V = \begin{bmatrix} 0 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$$

- (1) 请使用点积注意力，计算第一个头和第二个头的输出（Softmax 的计算公式为：

$$\text{softmax}(z_i) = \exp(z_i) / \sum_j \exp(z_j)$$

- (2) 假设 $W^O = \begin{bmatrix} 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 \end{bmatrix}^T$ ，计算多头自注意力的输出向量。

2. 假设训练语料为以下 6 句话（带<s>与</s>）：

<s> the cat sat on the mat </s>
 <s> the dog sat on the mat </s>
 <s> the cat ate the food </s>
 <s> the dog chased the cat </s>
 <s> the cat chased the mouse </s>
 <s> the mouse ate the food </s>

- (1) 请列出该语料库的词表（含<s>与</s>）。（3 分）
- (2) 请基于二元文法模型计算句子<s> the dog chased the mouse </s>的概率（写出计算过程，结果保留小数点后 5 位）。（7 分）

3. TinyBERT模型（TinyBERT-4L-312D）是BERT模型的轻量化版本，它继承了BERT的结构，采用层后归一化，其主要参数如下：

- 层数 $L=4$,
- 词向量的表示维度 $d_{\text{model}}=312$,

- 注意力头数 $h=12$,
- 前馈网络隐藏层维度 $d_{ff}=1248$

(1) 请画出TinyBERT模型的主要结构并标注重要的子层（包括箭头）。（5分）

(2) 请估算TinyBERT中所有编码器层的总参数量，给出每个子层的计算过程（忽略所有偏置项和归一化层）。（10分）